

Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow

Chapter 2 — End-to-End Machine Learning Project (Detailed Summary)

Chapter 2 adalah chapter paling penting dalam buku ini karena menjelaskan bagaimana proyek machine learning

dilakukan di dunia nyata secara end-to-end, bukan hanya fokus pada algoritma.

1. Framing the Problem

Langkah pertama adalah memahami masalah bisnis dan menerjemahkannya menjadi masalah machine learning.

Penentuan apakah masalah termasuk supervised, unsupervised, atau reinforcement learning sangat krusial.

Kesalahan di tahap ini akan membuat seluruh proyek gagal.

2. Selecting a Performance Measure

Metric harus dipilih sebelum training dimulai.

Contoh metric:

- RMSE untuk regresi
- Precision/Recall untuk klasifikasi

Metric harus sesuai dengan tujuan bisnis, bukan sekadar akurasi.

3. Getting the Data

Data bisa berasal dari:

- Database internal
- File CSV
- API
- Web scraping

Data mentah hampir selalu berantakan dan tidak siap pakai.

4. Exploring the Data

Exploratory Data Analysis (EDA) dilakukan untuk:

- memahami distribusi data
- mendeteksi outlier
- menemukan missing values
- melihat korelasi antar fitur

Visualisasi data membantu mengungkap pola tersembunyi.

5. Data Cleaning

Langkah ini mencakup:

- menangani missing values
- menghapus atau memperbaiki outlier
- memastikan tipe data benar

Data cleaning biasanya memakan waktu paling lama.

6. Feature Engineering

Feature engineering adalah seni dan ilmu.

Meliputi:

- membuat fitur baru
- encoding data kategorikal
- scaling dan normalisasi

Fitur yang baik lebih penting daripada algoritma yang canggih.

7. Splitting Data

Data dibagi menjadi:

- training set
- validation set
- test set

Test set hanya digunakan sekali di akhir.

8. Selecting and Training Models

Beberapa model dicoba:

- Linear Regression
- Decision Trees
- Random Forest

Pendekatan ini mencegah terlalu cepat terikat pada satu model.

9. Fine-Tuning Models

Hyperparameter tuning dilakukan dengan:

- Grid Search
- Randomized Search

Cross-validation digunakan untuk estimasi performa yang andal.

10. Evaluating the Final Model

Model terbaik dievaluasi menggunakan test set.

Ini adalah estimasi performa sesungguhnya di dunia nyata.

11. Deployment and Monitoring

Model yang sudah jadi harus:

- di-deploy
- dimonitor performanya
- diperbarui jika data berubah

Kesimpulan:

Machine learning adalah proses iteratif yang sistematis.

Keberhasilan proyek ML lebih ditentukan oleh pipeline dan proses daripada algoritma semata.